BÁO CÁO ĐỀ TÀI BÀI TẬP LỚN HỌC MÁY

Dự Đoán Ý Định Mua Hàng Trực Tuyến

Đánh Giá Thực Nghiệm 5 Thuật Toán Phân Loại Có Giám Sát

> Khai thác hành vi duyệt web, chỉ số Google Analytics và kỹ thuật cân bằng dữ liệu nhằm nhận diện khách hàng tiềm năng trước khi rời trang.

SINH VIÊN THỰC HIỆN

Hoàng Văn Đô (24107948)

Phan Hoàng Nhật (24100092)

ĐƠN VỊ

Khoa Khoa học Máy tính

Trường Đại học Phenikaa, Hà Nội

DỮ LIỆU & THỰC NGHIỆM

UCI Online Shoppers (12.330 phiên)

Pipeline Scikit-Learn Python

Bài Toán Tỷ Lệ Chuyển Đổi Trong E-Commerce

~15,5%

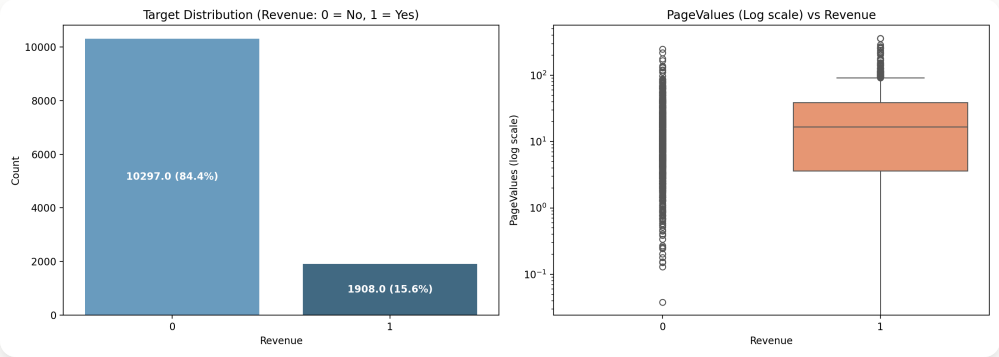
Tỷ lệ phiên phát sinh giao dịch thực tế (84,5% người dùng xem rồi rời đi)

Hàng triệu lượt truy cập mỗi ngày nhưng chỉ số ít tạo ra doanh thu. Can thiệp tặng voucher bừa bãi sẽ làm xói mòn lợi nhuận; bỏ qua không hỗ trợ thì vuột mất đơn hàng giá trị cao.

Mục tiêu cốt lõi:
Phân loại chính xác ý định thanh toán theo thời gian thực để kích hoạt can thiệp đúng người, đúng thời điểm.

1. **Bẫy Độ Chính Xác (Accuracy Paradox)**
   Nếu mô hình đoán "không ai mua", Accuracy vẫn đạt 84,5% nhưng vô giá trị thực tiễn. Mục tiêu bắt buộc phải tối ưu F1-Score, Recall và PR-AUC.
2. **Không Gian Đặc Trưng Đa Dạng & Thưa**
   Kết hợp giữa thông số lướt web liên tục và biến định danh (trình duyệt, hệ điều hành, tháng) sinh ra không gian 68 chiều sau mã hóa One-Hot.
3. **Thực Nghiệm Đối Đầu 5 Thuật Toán Cốt Lõi**
   Hồi quy Logistic, KNN, Cây quyết định, Rừng ngẫu nhiên (Random Forest) và SVM.

Khám Phá & Cấu Trúc Bộ Dữ Liệu UCI



Trái: Mất cân bằng nhãn (84,5% vs 15,5%) | Phải: Độ phân hóa cực mạnh của PageValues (thang log)

12.205 Phiên Truy Cập Hợp Lệ

10 Đặc Trưng Số (Hành vi truy cập):

- Lượt xem & thời lượng: `Administrative`, `Informational`, `ProductRelated`.
- Chỉ số đo lường web: `BounceRates`, `ExitRates`, `PageValues`, `SpecialDay`.

7 Đặc Trưng Danh Mục (Ngữ cảnh phiên):

- Thiết bị & người dùng: `VisitorType`, `OperatingSystems`, `Browser`, `Region`.
- Yếu tố thời gian & nguồn: `Month`, `Weekend`, `TrafficType`.

> **Quy luật then chốt phát hiện qua EDA:**
> Giá trị PageValues gần như bằng 0 đối với người không mua và tăng vọt ở nhóm hoàn tất đơn hàng.

Quy Trình Tiền Xử Lý Chống Rò Rỉ Dữ Liệu

A **Làm Sạch Dữ Liệu**

Loại bỏ 125 bản ghi trùng lặp tuyệt đối. Dữ liệu sạch hoàn toàn, không chứa giá trị khuyết thiếu (missing values).

B **Phân Chia Tập Dữ Liệu Phân Tầng (80/20)**

9.764 mẫu huấn luyện và 2.441 mẫu kiểm thử. Bảo toàn nguyên vẹn tỷ lệ 15,5% nhãn dương tính trên cả hai tập.

C **Đóng Gói Bằng ColumnTransformer**

Chuẩn hóa Z-score (`StandardScaler`) cho biến số; biến đổi biến giả (`OneHotEncoder`) an toàn với nhãn mới.

D **Cân Bằng Trọng Số Phạt Lớp (Cost-Sensitive)**

Áp dụng hệ số phạt nghịch đảo tỷ lệ mẫu $w_j = \frac{N}{2 \times N_j}$ trực tiếp vào hàm mất mát. Ép thuật toán phải chú trọng lớp thiểu số.

E **Kiểm Định Chéo Phân Tầng 5 Lượt (5-Fold CV)**

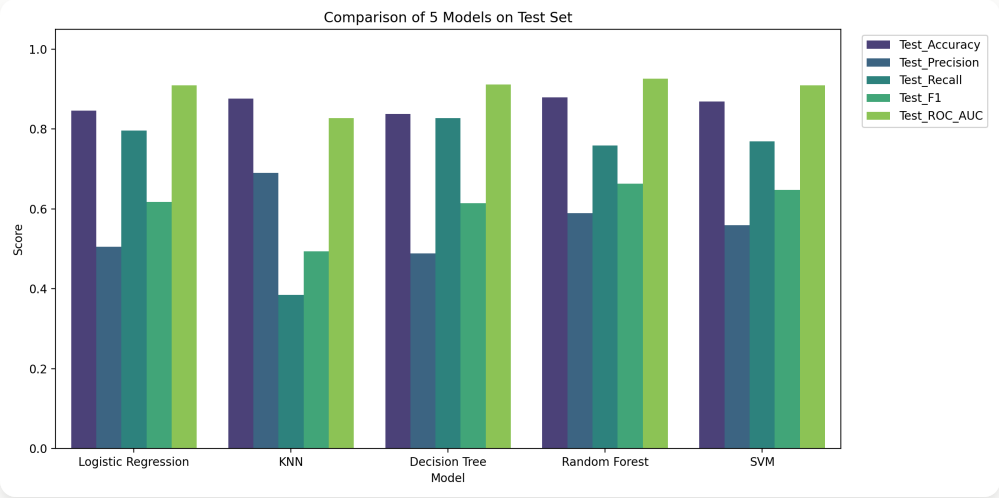
Kiểm tra độ ổn định tham số trước khi đánh giá khách quan trên tập kiểm thử độc lập.

Bảng Hiệu Năng 5 Mô Hình Trên Tập Kiểm Thử

Thuật Toán	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Hồi quy Logistic	84,60%	0,5050	0,7958	0,6179	0,9097	0,6627
K Láng Giềng (KNN, k=7)	87,67%	**0,6901**	0,3848	0,4941	0,8270	0,5717
Cây Quyết Định (CART, d=6)	83,78%	0,4892	**0,8272**	0,6148	0,9119	0,6673
★ Rừng Ngẫu Nhiên (Random Forest)	**87,96%**	**0,5894**	**0,7592**	**0,6636**	**0,9258**	**0,7096**
Máy Vector Hỗ Trợ (SVM – RBF)	86,89%	0,5589	0,7696	0,6476	0,9095	0,6695

Kết luận thực nghiệm: Random Forest áp đảo hoàn toàn ở 3 chỉ số then chốt: F1–Score (0,6636), ROC-AUC (0,9258) và PR-AUC (0,7096).

Phân Tích Chuyên Sâu Từng Thuật Toán



✓ Random Forest: Cân Bằng Xuất Sắc Nhất

Dung hòa tối ưu giữa Recall (75,9%) và Precision (58,9%). Phù hợp nhất cho môi trường triển khai thực tế.

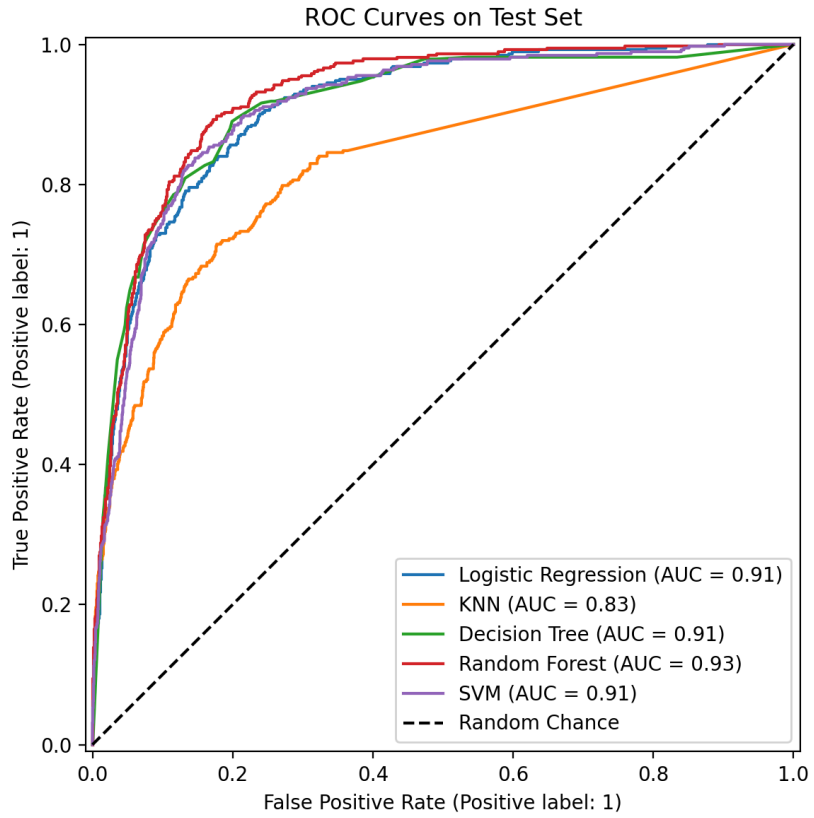
✗ KNN: Nạn Nhân Của Lời Nguyền Số Chiều

Precision cao (69,0%) nhưng Recall sụp đổ còn 38,5%. Bỏ sót hơn 61% khách mua vì khoảng cách Euclidean mất tác dụng trong không gian 68 chiều thưa.

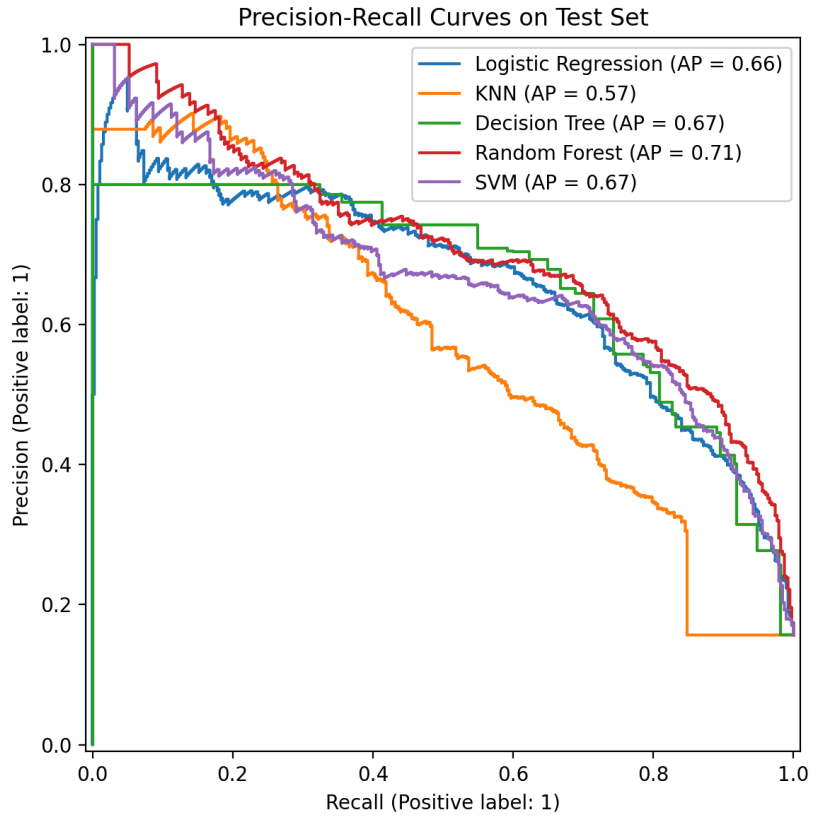
ℹ Decision Tree: Nhạy Cảm Cao, Sai Số Lớn

Bắt trúng 82,7% khách mua nhưng Precision chỉ đạt 48,9%, gây ra lượng cảnh báo giả rất lớn.

Khả Năng Phân Tách Lớp: ROC & PR Curves

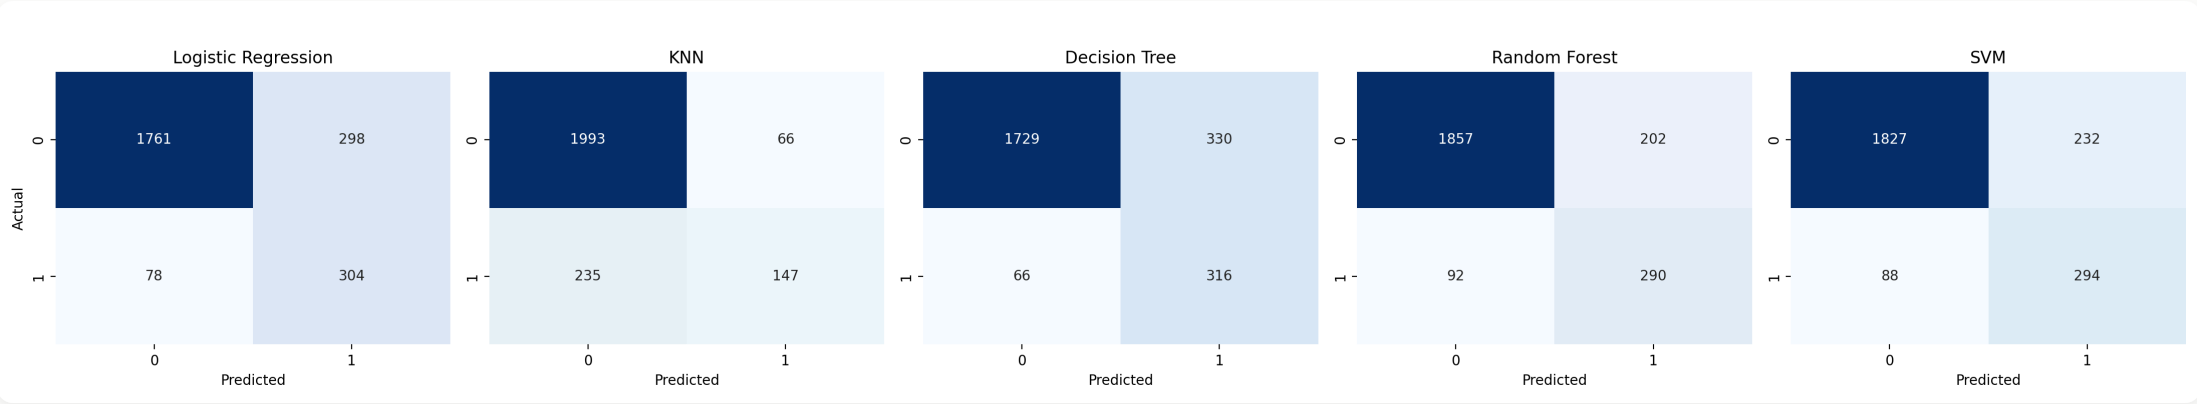


Đường Cong ROC: Random Forest dẫn đầu với AUC = 0,93, theo sau sát sao là Cây quyết định và SVM.



Đường Cong PR (Phản ánh mất cân bằng): Random Forest giữ vững độ chính xác vượt trội trên toàn dải phân ngưỡng (AP = 0,71).

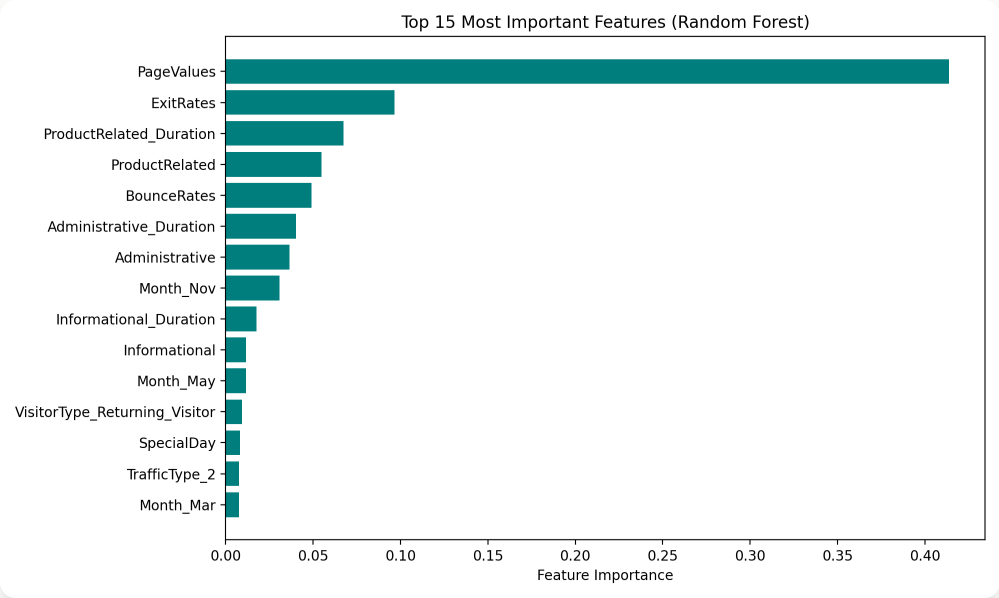
Đánh Đổi Vận Hành Qua Ma Trận Nhầm Lẫn



Decision Tree & Logistic Regression: Báo động giả cao (~250–310 ca). Thích hợp nếu ưu tiên không bỏ sót khách, nhưng tiêu tốn ngân sách ưu đãi không cần thiết.

Random Forest: Tiết giảm cảnh báo giả xuống chỉ 202 trường hợp, đồng thời bắt trúng 290 / 382 khách mua thật. Tổng chi phí sai số kinh doanh thấp nhất.

Yếu Tố Nào Thực Sự Quyết Định Giao Dịch?



Giải Mã Trọng Số Phân Nhánh (Gini)

1. **PageValues (Chiếm hơn 38% tỷ trọng)**
   Người dùng ghé qua các trang mang giá trị quy đổi tiền tệ cao là chỉ dấu gần như chắc chắn sẽ thực hiện thanh toán.

2. **ExitRates & BounceRates**
   Chỉ số tiêu cực mạnh. Tỷ lệ thoát và rời trang cao nhận diện nhóm người lướt web vãng lai, không có nhu cầu mua sắm.

3. **Tháng 11 (Month_Nov)**
   Biến danh mục có thứ hạng cao nhất. Phản ánh đúng hiệu ứng mùa mua sắm Black Friday và đợt kích cầu cuối năm.

Tổng Kết & Định Hướng Triển Khai Thực Tế

Bài Học Rút Ra Từ Dự Án

- **Mô hình tối ưu nhất:** Random Forest hoàn toàn vượt trội trên dữ liệu dạng bảng clickstream (F1: 0,6636, ROC-AUC: 0,9258).
- **Họ cây ưu việt hơn mô hình khoảng cách:** Cơ chế Bagging hấp thụ tốt phi tuyến và đặc trưng thưa, hoàn toàn khắc phục điểm yếu chí mạng của KNN.
- **Bắt buộc điều chỉnh trọng số lớp:** Nếu không cân bằng phạt lỗi, mô hình sẽ không có giá trị phát hiện trong kinh doanh.

Định Hướng Ứng Dụng Tiếp Theo

Đưa Vào Vận Hành Thực Tế:

Đóng gói Random Forest thành microservice suy luận luồng (độ trễ < 50ms), tự động kích hoạt can thiệp khi PageValues > 0.

Nâng Cấp Thuật Toán:

Thử nghiệm các họ Gradient Boosting nâng cao (XGBoost, LightGBM, CatBoost) kết hợp tối ưu siêu tham số Bayesian.

Xin chân thành cảm ơn! Mời Thầy Cô và các bạn đặt câu hỏi.